

广州花园酒店评论分析技术报告

第一章 评论聚类分析

1. 背景与目标

广州花园酒店的评论数据已有人工标注的 14 个类别标签（如”餐饮设施”、”前台服务”、”地铁交通”等），平均每条评论对应 2.80 个标签，其中 97.7% 的评论具有 2 个及以上标签。人工标注虽然准确，但存在固有局限：标注成本高、类别边界主观、难以动态扩展，且标注规则并不总能反映评论文本的实际聚集模式。本部分的目标是用数据驱动的无监督聚类方法重新发现评论主题，验证与人工分类的一致性，并解决多标签分配问题，最终输出带结构化标签的聚类结果。

2. 技术方案

2.1 文本向量化：TF-IDF

中文评论首先经 jieba 分词，过滤停用词（含通用停用词及酒店专有无意义词”花园酒店”、”入住”等），再用 TF-IDF (`max_features=3000`, `min_df=3`, `max_df=0.85`, `sublinear_tf=True`) 转化为 3000 维稀疏向量。选择 TF-IDF 而非词嵌入（如 Word2Vec）的原因在于：**聚类不需要跨语义泛化，TF-IDF 对主题词的区分更直接**；同时，TF-IDF 的稀疏矩阵便于后续 c-TF-IDF 判别词提取。

2.2 降维：UMAP

由于高维空间中欧氏距离趋于均匀，密度概念失效，因此 3000 维 TF-IDF 向量不能直接聚类。选用 UMAP 而非 PCA 是因为 UMAP 能保留**局部邻域结构**（非线性流形），而 PCA 只保留全局方差方向，对文本主题的局部聚集性捕捉较差。

UMAP 分两阶段进行：第一阶段降至 **50 维** (`min_dist=0.0`)，使同类评论更紧密，供 HDBSCAN 聚类；第二阶段降至 **2 维** (`min_dist=0.1`)，适当扩散，供人眼可视化。两次 UMAP 均用余弦距离 (`metric='cosine'`)，因为文本向量的方向比绝对长度更能反映语义相似性。

2.3 聚类：HDBSCAN

选择 HDBSCAN 而非 K-Means 的核心理由有三：(1) **无需预设簇数 k** ，让数据自行决定有多少个主题；(2) **支持噪声点**，那些内容太综合或太边缘的评论不会被强行归类，而是标记为噪声（本数据集中占 44.1%）；(3) **适应非球形簇**，评论主题的分布在语义空间中并非规则圆形。最终发现 14 个聚类，与人工标注类别数巧合一致，但这一结果并非预设。

参数选择：`min_cluster_size=30` 控制最小簇规模（低于 30 条的话题视为噪声），`min_samples=5` 控制核心点敏感度，`cluster_selection_method='eom'`（超额质量法）倾向于生成语义更纯的、数量适中的簇。

3. 关键工程问题与解决方案

3.1 问题一：施工噪音簇误匹配餐饮内容

初始多标签分配发现，大量含餐饮内容的语义段被错误分配到施工噪音簇（簇 8）。根本原因是：簇 8 的 TF-IDF 均值中心包含”早餐”、”自助”、”晚餐”等词，普通均值中心无法区分”这是噪音簇偶然包含的食物词”还是”食物词是噪音簇的本质特征”。

解决方案是引入 **c-TF-IDF（簇间 IDF 加权）**：

$$\text{c-TF-IDF}_{w,c} = \text{TF-IDF}_{w,c} \times \log\left(1 + \frac{N_c}{df_w + 1}\right)$$

其中 df_w 为词 w 出现在几个簇中。”早餐”在多个簇都有权重， df_w 大，簇间 IDF 小，乘下来权重被压低；而”施工”、”太吵”只在簇 8 出现， df_w 小，权重被放大。每簇取 top-30 判别词构成稀疏判别中心后，簇 8 的代表词变为：施工、噪音、太吵、不好、成就，食物词完全被淘汰。此外还加入后处理规则：若某段落的最佳匹配是施工噪音簇，但段落中不含”施工/噪音/太吵”等实词，则强制降级到次优匹配。

3.2 问题二：餐饮类别缺失

HDBSCAN 未产生独立的”餐饮”簇。原因是含餐饮内容的评论往往同时提及其他话题（住宿体验、地理位置等），在语义空间中较为分散，密度不足以聚集成簇。然而餐饮是业务上最重要的类别之一。

解决方案是引入**手工餐饮伪簇**（ID=100）：从 TF-IDF 词表中直接构造一个餐饮中心向量，包含早餐、自助、晚餐、餐厅、菜品、食材等餐饮核心词，同时将行政/酒廊等词清零，避免与行政酒廊簇（簇 2）抢竞争。这是一种半监督补充：用已知业务知识弥补纯数据驱动的盲区，最终 236 条评论（10.9%）被分配到餐饮标签。

3.3 多标签分配机制

为解决一条评论涉及多个主题的问题，将每条评论用 DashScope 嵌入（text-embedding-v3, 1024 维）按话题跳变处切分为若干语义段（平均 2.2 段/条），每段独立与判别中心矩阵做余弦匹配，汇总取频次最高的最多 3 个标签。最终平均 1.49 个标签/条，40.5% 的评论获得 ≥ 2 个标签。

4. LLM 语义标签生成

HDBSCAN 只输出簇编号，需要将每个簇转化为业务可读的标签。我们采用 DashScope qwen-turbo，向 LLM 提供每簇的 top-20 判别词和 3 条代表性评论样例，要求生成”【一级分类 - 二级细分】”格式的标签（一级固定为设施/服务/位置/体验四类）。

为防止 LLM 对相似簇生成重复标签，每次调用都将已生成的所有标签传入 prompt。即便如此，LLM 仍产生了 4 处错误（如将前台服务簇（簇 3）标注为”房间升级”，将整体口碑簇（簇 5）标注为已存在的”前台服务”重复标签），均通过 Patch 单元格直接覆盖修正。最终 15 个标签（14 个 HDBSCAN 簇 + 1 个手工餐饮簇）语义清晰、无重复。

5. 与人工标签的对比分析

5.1 类别对应关系

聚类结果与人工标注在**主要类别上高度吻合**，但两者在粒度和覆盖上存在差异（见表 1）。

表 1: 聚类标签与人工标签对应关系

聚类标签	对应人工标签	备注
【位置类 - 地铁便利性】（133 条）	地铁交通	高度吻合
【设施类 - 餐饮设施】（236 条）	餐饮设施	需手工伪簇补充
【服务类 - 前台服务】（59 条）	前台服务	高度吻合
【设施类 - 卫浴设施】（96 条）	房间设施	聚类更细分（专注卫浴）
【设施类 - 行政酒廊】（152 条）	餐饮设施/会员权益	人工未单独区分
【体验类 - 施工噪音】（62 条）	整体体验/无单独标签	聚类独立发现负面主题
【体验类 - 节日氛围】（67 条）	整体体验/无单独标签	聚类独立发现节庆主题
【体验类 - 回头意向】（192 条）	整体满意度	聚类捕捉行为信号
【服务类 - 生日客情】（43 条）	前台服务/特殊需求	聚类细粒度更高

5.2 差异分析

聚类的优势体现在以下方面。第一，粒度更细：人工标签中”餐饮设施”是一个大类，聚类则将行政酒廊（会员早餐+下午茶权益，152条）和普通餐饮（236条）明确分开，这对于不同业务线的分析更有价值。第二，发现人工未设定的类别：施工噪音（62条）和节日氛围（67条）在人工标注体系中没有独立类别，但聚类算法从数据中自然发现这两个有意义的主题，反映了一批客人的共同体验。第三，行为性标签：回头意向簇（192条，关键词为”下次还会来”等）是一种**行为意图信号**，在原始人工标签中归为笼统的”整体满意度”，聚类后可单独提取用于预测客户忠诚度。

聚类的不足体现在：平均每条评论仅 1.49 个标签，远低于人工的 2.80 个，原因是语义分段匹配的相似度阈值（0.05）过于保守，部分段落未能触发多标签；同时 44.1% 的评论被 HDBSCAN 归为噪声，需通过分段匹配兜底，覆盖率虽然完整，但主簇硬标签缺失。此外，聚类对短评（少于 5 词后分词）效果较差，这类评论更多依赖兜底规则而非真正的语义匹配。

5.3 结论

两套标签体系互为补充：人工标签精度高、覆盖全，适合作为评估基准；聚类标签能发现人工体系盲区、细化粒度、提取行为信号，尤其是能针对酒店特性生成多样化的标签（包含行政酒廊、生日客情等特殊细分模块），适合作为探索性分析和自动化扩展的工具。由于人工标签具备更高的通用性，更匹配 C 端用户选择酒店时的需求，我们在问答系统中仍然采用人工标签；但在实际应用中，可将聚类标签与人工标签同时保留，供不同下游任务选用。

6. 聚类结果汇总

聚类分析最终结果

最终得到 **15 个语义聚类标签**（14 个 HDBSCAN 自动发现 + 1 个手工餐饮伪簇），全部标签语义清晰、无重复。多标签分配结果：平均 1.49 标签/条， ≥ 2 标签占 40.5%， ≥ 3 标签占 8.8%，含餐饮标签 236 条（10.9%）。输出文件：filtered_comments_clustered.csv（含 6 个新增列）和 category_summaries_cluster.json（15 条类别元信息），可直接供 RAG 问答系统检索使用。

第二章 评论摘要生成与检索

2.1. 背景与目标

酒店评论 RAG（检索增强生成）问答系统包含五路混合检索机制：BM25 稀疏检索、向量相似度检索、反向 Query 检索、HyDE 假设文档扩展，以及**类别摘要检索**。其中，前四路均直接召回具体评论，而类别摘要检索的目标是：在回答用户问题时，提供超越单条评论的**宏观类别背景**，帮助 LLM 做出更全面、准确的综合判断。

本章聚焦于类别摘要的两个核心环节：（1）摘要的离线生成流程——如何从 2171 条原始评论提炼出 14 个类别的高质量摘要；（2）摘要的在线检索机制——如何在用户提问时精准召回相关类别摘要，并注入 LLM 生成答案。

2.2. 摘要生成

2.2.1 知识库结构与类别划分

评论数据共 2171 条，经人工多标签标注覆盖 14 个业务类别，包括：整体满意度（1855 条）、前台服务（1352 条）、餐饮设施（705 条）、房间设施（619 条）、交通便利性（465 条）、公共设施（277 条）、客房服务（261 条）、卫生状况（403 条）、周边配套（250 条）、退房/入住效率（105 条）、性价比（156

条)、安静程度 (147 条)、景观/朝向 (88 条)、价格合理性 (13 条)。平均每条评论对应 2.80 个标签, 97.7% 的评论具有 2 个及以上标签。

类别间样本量差异显著 (最多 1855 条, 最少 13 条), 这对摘要质量和向量检索可信度均有影响, 是后续优化中需要特别处理的维度。

2.2.2 分层聚合生成方法

直接将类别下全部评论拼接后输入 LLM 会超出上下文窗口 (尤其是 1855 条整体满意度评论), 且大量重复性内容会稀释关键信息。本章采用**分层聚合策略** (见表 2):

1. **分批摘要 (Batch Summarization)**: 将每类别的评论按批次 (每批约 30-50 条) 输入 qwen-turbo, 生成批次小结, 提取该批次的核心主题与高频词;
2. **关键词整合**: 对批次小结做关键词频次统计, 提取全类别 top-5 代表性关键词 (如”前台服务”类的热情周到、主动升级、员工点名表扬、服务两极化、高峰期效率);
3. **最终摘要合成 (Meta-Summarization)**: 将所有批次小结和关键词集中, 再次调用 LLM 生成最终摘要 (约 500-1000 字), 要求覆盖正负面评价、指出核心矛盾、保留具体细节。

表 2: 分层摘要生成流程

阶段	输入	模型	输出
批次摘要	30-50 条原始评论	qwen-turbo	批次小结 + 关键词
关键词聚合	所有批次关键词	词频统计	top-5 类别关键词
最终合成	全部批次小结	qwen-turbo	500-1000 字类别摘要

2.2.3 摘要质量评价

最终 14 条摘要平均长度约 650 字, 覆盖正面评价、负面评价与具体细节三个维度。以”前台服务”类摘要为例, 其明确指出服务热情度的两极分化——多位员工被高频实名表扬, 同时高峰期效率问题与个别员工短板亦有所记录, 体现了评论数据的真实分布。

2.3. 摘要检索机制

2.3.1 向量化方案：非对称检索

摘要知识库的构建与查询均基于 text-embedding-v4 (DashScope, 1024 维), 但两阶段使用不同的向量化策略, 构成**非对称检索** (Asymmetric Retrieval):

- **离线构建 (Document Side)**: 使用 embed_batch(), 对拼接文本 " 类别名: 关键词. 摘要前 300 字 " 进行普通嵌入, 向量充分表达文档语义;
- **在线检索 (Query Side)**: 使用 embed_query(), 额外传入 text_type="query" 和任务指令

"Given a hotel review query, retrieve relevant hotel reviews that answer the query."

该指令激活 text-embedding-v4 的指令微调能力, 将查询向量拉向”文档回答”的语义空间, 而非”关键词匹配”空间。

非对称检索相较于对称检索 (query 和 document 用同一策略), 在短查询/长文档场景下可显著提升召回率, 尤其对”游泳池干净吗”这类口语化问题与长篇摘要文本的匹配效果更为明显。

此外, embedding 文本由原始方案的**仅关键词** (约 30 字) 升级为**类别名 + 关键词 + 摘要前 300 字** (约 330 字), 使向量包含足够的语义内容, 避免了短文本向量退化为关键词集合的问题。

2.3.2 优化 A：相似度阈值过滤

原方案固定返回 top-3 摘要，不论余弦相似度高低。在 14 个类别中，即使最相关的类别相似度仅为 0.20，仍会被召回并注入 LLM prompt，引入噪声。

优化方案引入 **相似度阈值** ($\tau = 0.25$)：相似度低于阈值的类别摘要不参与最终结果，候选池同时扩大至 8 条以覆盖过滤后仍能保留足够结果。此外，若同一类别存在多个匹配文档（如原始摘要与 QA 变体），按类别去重，只保留最高分的一条。

$$\text{摘要}_i \in \text{结果} \iff \text{cosine_sim}(q, d_i) \geq \tau$$

其中 q 为查询向量， d_i 为第 i 个摘要文档向量， $\tau = 0.25$ 为过滤阈值。

2.3.3 优化 B：意图规则混合召回

纯向量检索对口语化短查询（如”前台怎么样”）存在 Gap——由于 query 向量维度高，在 14 类摘要构成的小索引中，语义对齐可能不稳定。本项目已有意图检测模块 (`detect_intent()`)，基于关键词词典对查询进行意图分类，但原始实现中摘要检索完全未利用该信号。

优化方案在向量检索的基础上，叠加一层**意图 → 类别规则映射** (表 3)：若意图关键词命中且对应类别未出现在向量结果中，则直接从 ChromaDB 按类别名查询并强制补入结果，标记来源为 `summary_rule`。

表 3: 意图 → 摘要类别映射规则

识别到的意图	强制补充的摘要类别
早餐	餐饮设施
房间	房间设施、卫生状况
服务	前台服务、客房服务、退房/入住效率
设施	公共设施
位置	交通便利性、周边配套

最终排序策略：向量召回结果按相似度降序排列，规则补充结果附后，整体截取前 3 条。这确保了向量检索的精度主导权，同时规则提供兜底保障。

2.3.4 优化 C：检索导向的 QA 变体生成

原始摘要为叙述式长文本（约 650 字），其向量与用户的短查询之间存在 **Query-Document Gap**：用户提问”游泳池水温怎么样”，但摘要文本以”综合 X 条评论，酒店公共设施整体表现卓越……”开头，两者的语义空间并不对齐。

优化方案在摘要知识库中为每个类别额外生成 **3 条 QA 变体句**，每句 20-50 字，风格类似对用户问句的直接回答，分别覆盖：主要优点、需注意的问题、一个具体特色细节。QA 变体由 `qwen-turbo` 根据完整摘要生成，embedding 后存入同一 ChromaDB 集合，`document` 字段仍指向完整摘要，`metadata` 中额外保留 `qa_text` 字段记录原始变体句。

这样，向量检索命中 QA 变体时，LLM 获得的仍是完整的类别背景摘要，但召回路径更贴近用户问句形式，有效缩短了 Query-Document Gap（如图 1 所示）。




图 1: QA 变体作为检索桥接层, 缩短用户查询与摘要文档之间的语义距离

2.4. 摘要在 LLM 生成中的使用

召回的类别摘要以结构化方式注入 LLM prompt, 位于具体评论列表之前, 形成两层上下文:

Prompt 结构

【类别背景知识】 (基于大量评论的综合分析):

【前台服务】 基于 1352 条评论, 前台服务是酒店体验的核心亮点…… (截取前 300 字)

【房间设施】 酒店房间设施整体呈现显著的”新旧并存”特征…… (截取前 300 字)

【真实住客评论】:

评论 1 **【大床房, 评分 4.5】**: 前台小姐姐超级贴心……

评论 2 **【标准房, 评分 3.0】**: 房间有点旧, 设施一般……

这种”宏观背景 + 具体证据”的双层结构, 使 LLM 能在生成答案时兼顾全局趋势 (来自摘要) 与个体案例 (来自评论), 回答质量相比纯评论上下文有明显提升, 尤其对”整体上评价怎么样”类泛化问题效果更显著。每条摘要截取前 300 字注入, 避免因摘要过长挤占评论的上下文空间。

2.5. 摘要结果汇总与改进方向

摘要检索当前实现总览

知识库: 14 条类别摘要 (原始) + 42 条 QA 变体, 存储于 ChromaDB 本地持久化库 (data/chroma_db/), 向量维度 1024, 余弦相似度空间。

检索机制: 非对称向量检索 (候选池 8 条) → 余弦相似度阈值过滤 ($\tau = 0.25$) → 类别去重 → 意图规则补充 → 截取 top-3。

生成注入: 召回摘要以”类别背景知识”块前置注入 prompt, 每条限 300 字, 与真实评论构成双层上下文。

主要改进对比 (见表 4):

表 4: 摘要检索机制改进前后对比

维度	改进前	改进后
检索方式	<code>get()</code> 全量拉取, 固定返回前 3 条	<code>query()</code> 向量相似度检索, 8 候选池
Embedding 文本	仅关键词 (约 30 字)	类别名 + 关键词 + 摘要前 300 字 (约 330 字)
查询向量化	<code>embed_batch()</code> 无指令	<code>embed_query()</code> 加 <code>task</code> 指令 (非对称)
相关性过滤	无, 始终返回 3 条	余弦相似度阈值 $\tau = 0.25$ 过滤
意图利用	未使用意图信号	规则映射强制补充命中类别
LLM 上下文	摘要从未传入 LLM	双层 <code>prompt</code> (背景 + 评论), 300 字截断
QA 变体	无	每类别 3 条变体句, 缩短 Query Gap

后续可优化方向:

1. **阈值自适应**: 当前阈值 $\tau = 0.25$ 为固定值, 可根据意图置信度动态调整——高置信度查询收紧阈值以保证精准, 低置信度放宽以增加覆盖;
2. **评论数量加权**: 对余弦相似度叠加评论数量权重 $\text{score}' = \text{score} \times (1 + \alpha \log(\text{comment_count}))$, 避免 13 条评论的”价格合理性”类别与 1352 条评论的”前台服务”类别在同等条件下获得相同权重;
3. **扩展 Query 投票**: 利用已有的 `expand_intent()` 对多个扩展问题分别检索, 对类别分数加权平均, 进一步提升召回稳定性。